به نام خدا



دانشگاه تهران

دانشکدگان فنی

دانشکده مهندسی برق و کامپیوتر



درس بازیابی هوشمند اطلاعات

پاسخ بخش تئوری تمرین ۴

نام و نام خانودگی: سهیل حاجیان منش

شماره دانشجویی: 810100119

آذر ماه ۱۴۰۴

فهرست

اظهارنامه 3

سؤال ۱ – روابط Word Association 3

الف 3

ب 3

پ 3

سؤال ۲ – تحلیل Mutual Information 3

الف 3

ب 3

سؤال ۳ – ماهیت فضای Word Embedding 3

الف 3

ب 3

سؤال ۴ – مقایسه CBOW و Skip-gram 4

سؤال ۵ – رویکردهای Pointwise، Pairwise و Listwise در LTR 4

سؤال ۶ – سازگاری LambdaRank با معیارهای رتبه‌بندی 5

الف 5

ب 5

پ 5

سؤال ۷ – شباهت واژگان با ویژگی‌های Interpretable 5

الف 5

ب 5

پ 6

اظهارنامه

تأیید می کنم که از LLM ها مطابق با دستورالعمل های بارگذاری شده در سامانه Elearn درس به طورمسئولانه استفاده کرده ام. تمام اجزای کار خود را درک میکنم و آماده بحث شفاهی درباره آنها هستم.

سؤال ۱ – روابط WORD ASSOCIATION

الف

رابطه paradigmatic از نوع جایگزینی است. یعنی واژه هایی که می توانند در یک جایگاه و نقش یکسان در یک جمله جایگزین یکدیگر شوند و همچنان جمله معنادار باشد.

رابطه syntagmatic از نوع هم وقوعی است. یعنی واژه هایی که احتمال اینکه در یک جمله ظاهر شوند بالا است.

ب

Paradigmatic : شباهت جانشینی و هم نقش بودن را مدل می کند.

Syntagmatic : شباهت هم موضوعی و هم آیندی را مدل می کند.

پ

Paradigmatic : cat و dog هر دو در جمله "My ---- eats meat." می توانند بیایند و نقش مشابهی داشته باشند.

Syntagmatic : واژه های eat و food احتمال اینکه همزمان در یک جمله زیاد شوند زیاد است چون به یک موضوع اشاره دارند اما لزوما نمی توانند جایگزین هم شوند.

سؤال ۲ – تحلیل MUTUAL INFORMATION

الف

MI میزان وابستگی آماری بین دو واژه را می‌سنجد و به شباهت معنایی دو واژه کاری ندارد. هر چه احتمال وقوع همزمان دو واژه در یک جمله بیشتر باشد، MI بیشتر می شود.کلماتی که زیاد با هم در یک جمله ظاهر می شوند، معمولا هم معنی نیستند و صرفا در یک موضوع واحد کاربرد دارند. به همین علت MI چون صرفا به رخداد واژه ها در متن نگاه می کند، برای تشخیص این رابطه ها مناسب است.

ب

مثلاً doctor و hospital ، این واژه‌ها مترادف نیستند، اما در جملات با موضوع مرتبط با سلامتی و پزشکی معمولاً با هم ظاهر می‌شوند، به همین دلیل MI بالایی دارند.

سؤال ۳ – ماهیت فضای WORD EMBEDDING

الف

بردارهای embedding الگوهای *هم‌وقوعی واژه‌ها در متن* را در خودشان فشرده می‌کنند. یعنی اطلاعاتی از شباهت معنایی و موضوعی بین کلمات. این فضا حاصل یادگیری از context است، نه تعریف دستی معنا.

اطلاعات معنایی: کلمات یا اسناد هم‌معنی به هم نزدیک می‌شوند.

الگوی استفاده در متن: واژه هایی که در متن‌های مشابه می‌آیند، بردار مشابه دارند.

موضوع کلی Topic : مثلاً متن‌های مرتبط با IR یا بینایی ماشین جدا خوشه می‌شوند.

ب

در این فضا، بعضی روابط معنایی به‌صورت *برداری و خطی* ظاهر می‌شوند. یعنی تفاوت بین دو مفهوم می‌تواند با یک بردار ثابت تقریب زده شود.

چون مدل در طول آموزش یاد گرفته که «پادشاهی» یک جهت معنایی است و «جنسیت» یک جهت دیگر. کم‌کردن man و اضافه‌کردن womanیعنی حذف مؤلفه‌ی مردانه و افزودن مؤلفه‌ی زنانه، و نتیجه به برداری نزدیک به queen می‌رسد. این دقیقاً همان خاصیت خطی بودنembedding هاست که اشاره شد.

سؤال ۴ – مقایسه CBOW و SKIP-GRAM

- ورودی هر مدل چیست؟
  - SKIP-GRAM : کلمه هدف
  - CBOW : همسایه های کلمه هدف
- خروجی هر مدل چیست؟
  - SKIP-GRAM : کلمات اطراف کلمه هدف (*context*)
  - CBOW : کلمه هدف
- کدام مدل برای کلمات پرتکرار بهتر است و چرا؟

برای کلمات پرتکرار، contextهای زیادی وجود دارد و چون CBOW یک روش Context-driven است، میانگین‌گیری روی این‌context ها باعث می‌شود نویز کمتر شود و یادگیری پایدارتر و سریع‌تر باشد

- کدام مدل برای کلمات کم تکرار بهتر عمل میکند و چرا؟

Skip-GRAM. چون کلمات کم تکرار context های کمی دارند روش CBOW مناسب نیست. اما در روش SKIP-GRAM با هربار تکرار کلمه یک context جدید یاد گرفته می شود و اطلاعات بیشتری از کلمه استخراج می شود و در نتیجه مدل بهتر می تواند نمایش برداری آن کلمه را یاد بگیرد.

سؤال ۵ – رویکردهای POINTWISE، PAIRWISE و LISTWISE در LTR

Pointwise

- **چه چیزی را مدل می‌کند؟** هر زوج (query, document) بصورت مستقل؛ Label درجه‌ی ارتباط سند با پرس و جو است.
- **تابع هدف:** رگرسیون یا طبقه‌بندی روی درجه ارتباط (مثلا Mean Squere Error روی تفاوت Label)
- **مزایا/محدودیت‌ها** : ساده و پیاده‌سازی راحت؛ اما ترتیب رتبه‌ها و جایگاه اسناد در لیست را مستقیماً در نظر نمی‌گیرد و همچنین وقتی تعداد اسناد مرتبط با query ها خیلی متفاوت باشد، queryهایی با اسناد بیشتر بر loss کلی غالب می‌شوند **و** یادگیری نامتوازن می‌شود.

Pairwise

- **چه چیزی را مدل می‌کند؟** رتبه بندی نسبی بین دو سند برای یک query . Label می‌گوید کدام سند بالاتر است.
- **تابع هدف** :کمینه‌کردن خطای جفت‌ها. (مثلا Ranking SVM)
- **مزایا/محدودیت‌ها** :ترتیب نسبی را بهتر می‌گیرد؛

1. وقتی چندین درجه ربط داریم، تبدیل آن‌ها به ترجیح دوتایی باعث می‌شود اطلاعات ظریف‌تر درباره میزان ربط از بین برود.
2. تعداد جفت‌سندها برای هر query توزیع بسیار نامتوازنی دارد؛ بعضی queryها جفت‌های خیلی بیشتری تولید می‌کنند و روی آموزش غالب می‌شوند.
3. Pairwise نسبت به labelهای نویزی حساس‌تر است، چون یک خطای کوچک می‌تواند چندین جفت را اشتباه کند.
4. اغلب الگوریتم‌های pairwise جایگاه واقعی سند در لیست نهایی را در تابع هدف در نظر نمی‌گیرند؛ یعنی تفاوت بالای لیست و پایین لیست دیده نمی‌شود.

Listwise

- **چه چیزی را مدل می‌کند؟** کل لیست اسناد یک query با هم؛ label کل توزیع ربط‌هاست.

- **تابع هدف :** یا مستقیماً معیار رتبه‌بندی را تقریب می‌زند ، یا loss لیستی تعریف می‌کند. (Measure-specific vs Non Measure-specific Loss)
- **مزایا**
  - همه‌ی اسناد مرتبط با یک query را به‌صورت یک واحد یادگیری در نظر می‌گیرد، نه جداگانه.
  - جایگاه رتبه (rank positionمستقیماً در تابع loss دیده می‌شود و روی یادگیری اثر می‌گذارد.
- **محدودیت‌ها**
  - پیچیدگی محاسباتی بالاتری دارد و آموزش آن سخت‌تر است.
  - با وجود درنظرگرفتن position، استفاده از اطلاعات جایگاه هنوز به‌طور کامل و ایده‌آل انجام نمی‌شود.

کدام با NDCG سازگارتر است و چرا؟

- Listwise چون تغییرات در بالای لیست وزن بیشتری می‌گیرند و مستقیماً به جایگاه‌ها حساس‌اند؛ دقیقاً همان چیزی که NDCG می‌سنجد.

سؤال ۶ – سازگاری LAMBDARANK با معیارهای رتبه‌بندی

الف

در LambdaRank به‌جای مشتق‌گیری مستقیم از معیارهایی مثل NDCGکه مشتق‌پذیر نیستند، یک gradient مصنوعی به نام λ تعریف می‌شود. این λ نشان می‌دهد اگر جای دو سند عوض شود، چقدر کیفیت رتبه‌بندی تغییر می‌کند.

ب

چون در معیارهایی مثل NDCG، اسناد بالای لیست وزن بیشتری دارند. بنابراین جابه‌جایی دو سند در رتبه‌های بالا افت یا بهبود بیشتری در NDCG ایجاد می‌کند و λ بزرگ‌تری می‌گیرد.

پ

LambdaRank مقدار λ را متناسب با ΔNDCG تنظیم می‌کند؛ یعنی هرچه تأثیر یک جابه‌جایی روی NDCG بیشتر باشد، مدل فشار بیشتری برای اصلاح آن می‌گیرد. یعنی در واقع بدون بهینه‌سازی مستقیم NDCG، با تغییرات آن سازگار است.

سؤال ۷ – شباهت واژگان با ویژگی‌های INTERPRETABLE

الف

$$dog = [1 \quad 1 \quad 0 \quad 0 \quad 0 \quad 0]$$

$$cat = [1 \quad 1 \quad 0 \quad 0 \quad 0 \quad 0]$$

$$bird = [1 \quad 0 \quad 1 \quad 0 \quad 0 \quad 0]$$

$$apple = [0 \quad 0 \quad 0 \quad 1 \quad 0 \quad 1]$$

$$banana = [0 \quad 0 \quad 0 \quad 1 \quad 0 \quad 1]$$

$$car = [0 \quad 0 \quad 0 \quad 0 \quad 1 \quad 0]$$

ب

$$cosine\ similarity\ (A, B) = \frac{A.B}{||A|| \times ||B||}$$

$$cosine\ similarity\ (cat, dog) = \frac{2}{\sqrt{2} * \sqrt{2}} = 1$$

$$cosine\ similarity\ (bird, dog) = \frac{1}{\sqrt{2} * \sqrt{2}} = 0.5$$

$$cosine\ similarity\ (banana, apple) = \frac{2}{\sqrt{2} * \sqrt{2}} = 1$$

$$cosine\ similarity\ (apple, dog) = \frac{0}{\sqrt{2} * \sqrt{2}} = 0$$

$$cosine\ similarity\ (car, apple) = \frac{0}{1 * \sqrt{2}} = 0$$

پ

- **کدام جفتها بیشترین شباهت را دارند؟** جفت های (cat,dog) و (banana,apple) بیشترین شباهت را دارند.
- **چه نوع شباهتی در این فضای interpretable اندازهگیری شده است؟** در این فضا، شباهت بین کلمات فقط بر اساس ویژگی‌هایی سنجیده می‌شود که از قبل مشخص کرده‌ایم(مثل حیوان بودن، دم داشتن، خوراکی بودن و ...) یعنی اگر دو کلمه ویژگی‌های مشترک بیشتری داشته باشند، شبیه‌تر حساب می‌شوند و اگر نداشته باشند، کاملاً نامشابه‌اند.
- **این شباهتها چگونه با شباهتی که از word embedding انتظار داریم تفاوت دارد؟** برخلاف word embedding، اینجا شباهت‌های پنهان، بافتی یا موضوعی (syntagmatic) دیده نمی‌شوند.
- **به نظر شما کدام نوع نمایش برای مدل کردن paradigmatic مناسبتر است و کدام برای Syntagmatic ?** برای مدل‌کردن paradigmatic، این نوع نمایش interpretable مناسب‌تر است .اما برای syntagmatic، embeddingها یا MI بهتر عمل می‌کنند.